

Acțiunile business-ului TESLA

1. Despre business

Tesla, Inc. proiectează, dezvoltă, produce, închiriază și vinde vehicule electrice și sisteme de generare și stocare a energiei la nivel internațional, în Statele Unite, China, Olanda, Norvegia etc.

Compania a fost cunoscută anterior sub numele de Tesla Motors, Inc. și și-a schimbat numele în Tesla, Inc. în februarie 2017. Tesla, Inc. a fost fondată în 2003 și are sediul central în Palo Alto, California.

Compania operează pe două segmente: **automotive** și **generarea și stocarea energiei**. **Segmentul Automotive** oferă berline și vehicule utilitare sport. De asemenea, oferă componente și sisteme de propulsie electrică și servicii pentru vehicule electrice prin locațiile de servicii deținute de companie și tehnicienii de servicii mobile Tesla. Compania vinde și vehicule uzate. Acest segment comercializează și vinde produsele printr-o rețea de magazine și galerii deținute tot de companie, precum sau prin propriul site.

Segmentul de generare și stocare a energiei oferă produse de stocare a energiei, cum ar fi sisteme de baterii reîncărcabile litiu-ion pentru utilizare în case, instalații industriale, comerciale și rețele utilitare. Tesla proiectează, produce, instalează, întreține, închiriază și vinde produse de producere a energiei solare și de stocare a energiei către clienți rezidențiali și comerciali.

Tesla oferă servicii de asigurare a vehiculelor, precum și energie regenerabilă.

2. Istoric

În **ianuarie 2010**, Tesla a primit un împrumut de **465 milioane de dolari** de la Departamentul Energiei al SUA, pe care l-a rambursat în 2013.

În **mai 2010**, Tesla a cumpărat ceea ce va deveni Fabrica Tesla din Fremont, California, **pentru 42 de milioane de dolari** și a deschis fabrica în **octombrie 2010** unde va produce Modelul S.

În **aprilie 2015**, compania și-a prezentat pachetele de baterii **Powerwall** pentru casă și **Powerpack** industriale și a primit comenzi în valoare de **800 de milioane de dolari** în decurs de o săptămână de la prezentare.

În noiembrie 2016, Tesla a achiziționat SolarCity.

În iulie 2018, compania a donat 37,5 milioane de dolari pentru educația K-12 STEM din Nevada.

Din iulie 2019 până în iunie 2020, Tesla a raportat patru trimestre profitabile la rând pentru prima dată, ceea ce a făcut-o eligibilă pentru includere în S&P500. Tesla a fost adăugată la index pe 21 decembrie 2020. Tesla a fost cea mai mare companie adăugată vreodată și a șasea cea mai mare companie din index la momentul includerii. Tesla a fost cea mai mare companie adăugată vreodată și a șasea cea mai mare companie din index la momentul includerii. Pe măsură ce investitorii au încercat să cumpere mai multe acțiuni ca urmare a acestei includeri, unii analiști, precum Ryan Brinkman sau J.P.Morgan, au sugerat investitorilor să fie prudenți, deoarece Tesla a fost supraevaluată „dramatic”. În 2020, prețul acțiunilor Tesla a crescut cu 740%, iar începând din decembrie 2020, capitalizarea sa de piață era mai mare decât mari producători de automobile.

În **ianuarie 2020, Tesla a donat 5 milioane de yuani (723.000 de dolari)** către Chinese Center for Disease Control and Prevention pentru a combate **focarul COVID-19**.

În martie 2020, Tesla a început livrările crossover-ului Model Y.

Obiectivul 1:

Vrem să vedem dacă prețul acțiunilor Tesla este random walk, ceea ce înseamnă că varianța randamentelor este o funcție liniară de timp.

	Open	High	Low	Close	Volume	Dividends	Stock Splits
Date							
2010-06-29	3.800000	5.000000	3.508000	4.778000	93831500	0	0.0
2010-06-30	5.158000	6.084000	4.660000	4.766000	85935500	0	0.0
2010-07-01	5.000000	5.184000	4.054000	4.392000	41094000	0	0.0
2010-07-02	4.600000	4.620000	3.742000	3.840000	25699000	0	0.0
2010-07-06	4.000000	4.000000	3.166000	3.222000	34334500	0	0.0
...
2021-01-21	855.000000	855.719971	841.419983	844.989990	20598100	0	0.0
2021-01-22	834.309998	848.000000	828.619995	846.640015	19977100	0	0.0
2021-01-25	855.000000	900.400024	838.820007	880.799988	41173400	0	0.0
2021-01-26	891.380005	895.900024	871.599976	883.090027	23131600	0	0.0
2021-01-27	870.349976	891.500000	858.659973	864.159973	27334000	0	0.0

: 2664 rows × 7 columns

Fig.1 Date istorice ale acțiunilor Tesla



Fig.2 Prețurile acțiunilor Tesla

Ipoteza de piață eficientă

Vom testa eficiența pieței în formă slabă, adică vom include doar istoricul tranzacțiilor.

Studiile empirice pot doar să constate cât de aproape sau cât de departe este o piață de capital de acest ideal.

Am luat prețul de închidere pentru Tesla în perioada **2010-06-29** până la **2021-01-27**.




Fig.3 Prețul de închidere ajustat

A. Variance Ratio Test

Funcția folosită se numește *VRTest* (vezi cod) și are trei parametri: **x** - prețul de închidere, **k** - se referă la numărul de sub perioade luate în calcul (**q**), **alfa** - este nivelul de semnificație al testului.

Aceste formule au fost implementate pentru Variance Ratio Test în ipoteza cea mai generală de heterodasticitate. La apelarea funcției se returnează pentru fiecare **q**: variance ratio, p-value și valorile lui **z** și **q**.

Variance Ratio Test - examinează predictibilitatea datelor din seriile de timp.




Fig.4 Intervalul de încredere pentru VR(q)

Ipoteze:
$$\begin{cases} H_0 : p_t \text{ este random walk} \\ H_A : p_t \text{ nu este random walk} \end{cases}$$

Graficul de mai sus arată pentru fiecare **q** (2,4,8,16) intervalul de încredere pentru VR(q), cu probabilitatea 95%.

Linia egală cu unu (linia neagră) evidențiază VR în ipoteza de random walk.

Concluzie:

Graficul ne spune că acceptăm ipoteza de random walk pentru că intervalul de încredere conține valoarea 1.

Individual Variance Ratio Tests

$$\begin{cases} H_{0i} : VR(q_i) = 1 \\ H_{Ai} : VR(q_i) \neq 1 \end{cases}$$

	q	VR test	Std. Error	z statistic	P-value
0	2	0.994650	0.031150	-0.171757	0.863629
1	4	1.010581	0.057529	0.183932	0.854067
2	8	0.986579	0.086612	-0.154955	0.876857
3	16	1.026859	0.120315	0.223241	0.823348

Pentru $q=2 \Rightarrow VR=0,99$ aceasta înseamnă că randamentele au autocorelație negativă de ordinul 1, valoarea testului z este $-0,1717$, iar P -value este $0,86 > 0,05 \Rightarrow$ acceptăm ipoteza nulă ($H_0: VR(2)=1$). Același lucru se întâmplă și în cazul $VR(8)=1$.

Pentru $q=4$: $VR=1,01$ valoarea testului z este $0,1839$, iar P -value este $0,85 > 0,05 \Rightarrow$ acceptăm ipoteza nulă ($VR(4)=1$). Același lucru se întâmplă și în cazul $VR(16)=1$.

În acest caz, pentru acțiunea Tesla acceptăm, cu probabilitatea 95%, ipoteza de random walk.

Problema la Individual Variance Ratio Tests este că nu avem pentru aceeași perioadă, același nivel de încredere al testelor.

B. Multiple Variance Ratio Test

Vom aplica **Multiple Variance Ratio Test** - Chow-Denning's (1993)

Ajută la obținerea unei concluzii globale unitare.

La acest test, pentru fiecare „ q ”, calculăm raportul varianțelor și testul z . Valoarea testului este maximum din modulul testelor z individuale. Acest maxim urmează o distribuție de tip student numită studentized maximum modulus.

$$SMM(\alpha, m, \infty) = z_{\alpha^+/2} \text{ unde } \alpha^+ = 1 - (1 - \alpha)^{1/m}$$

Dacă valoarea maximă a modulelor „ z ” este mai mare decât valoarea critică la pragul de semnificație α , unde m este numărul de teste individuale, iar numărul gradelor de libertate este infinit, atunci respingem ipoteza de random walk.

Aplicând testul **Multiple Variance Ratio** pentru acțiunile Tesla în perioada **2010-06-29** până 2012-01-28 se concluzionează că nu se poate respinge ipoteza de random walk.

	z Statistic	Critical z	Decision
0	0.223241	2.490915	Cannot reject the null hypothesis of random walk

Acum, știm că prețurile de închidere Tesla au proprietatea de random walk, ceea ce înseamnă că știm de la început că ipoteza nulă este adevărată.

Folosim pachetul **arch.unitroot** care are două argumente seria prețului și lagul maxim (doi la puterea a patra, adică 16).

```

1 from arch.unitroot import VarianceRatio
2 vr = VarianceRatio(df_1, 16)
3 print(vr.summary().as_text())

```

```

Variance-Ratio Test Results
=====
Test Statistic          0.752
P-value                 0.452
Lags                    16
=====

```

Fig.5

0.752 este testul z; p-value=0.45>0.05 => Acceptăm ipoteza nulă: Prețurile de închidere Tesla sunt random walk.

C. Testul Augmented Dickey-Fuller

Facem același lucru folosind testul Augmented Dickey-Fuller.

```

1 from arch.unitroot import ADF
2
3 adf = ADF(df_1)
4 print(adf.summary().as_text())

```

```

Augmented Dickey-Fuller Results
=====
Test Statistic          8.369
P-value                 1.000
Lags                    28
=====

Trend: Constant
Critical Values: -3.43 (1%), -2.86 (5%), -2.57 (10%)
Null Hypothesis: The process contains a unit root.
Alternative Hypothesis: The process is weakly stationary.

```

Fig.6

p-value=1>0.05 => Acceptăm ipoteza nulă: Prețurile de închidere Tesla sunt random walk.

Testele **Variance Ratio** si **ADF** pentru **iulie 2019 până în iunie 2020 când Tesla a raportat patru trimestre profitabile la rând**

```
stock = get_data('TSLA' , start_date = '2019-7-1', end_date = '2020-7-1')
```




Fig.7 Seria de timp -perioada: '2019-7-1' -- '2020-7-1'




Fig.8 Intervalul de încredere pentru VR(q)

```
1 import quandl
2 df = tickerData.history(period='1d', start='2019-7-1', end='2020-7-1')
3 df_1 = df['Close']
4
```

```
1 from arch.unitroot import VarianceRatio
2 vr = VarianceRatio(df_1, 16)
3 print(vr.summary().as_text())
```

```
Variance-Ratio Test Results
=====
Test Statistic          0.760
P-value                 0.447
Lags                    16
-----
```

Computed with overlapping blocks (de-biased)

```
1 from arch.unitroot import ADF
2
3 adf = ADF(df_1)
4 print(adf.summary().as_text())
```

```
Augmented Dickey-Fuller Results
=====
Test Statistic          0.196
P-value                 0.972
Lags                     0
-----
```

Trend: Constant
Critical Values: -3.46 (1%), -2.87 (5%), -2.57 (10%)
Null Hypothesis: The process contains a unit root.
Alternative Hypothesis: The process is weakly stationary.

Fig.9 Seria de timp pe intervalul (2019-7-1, 2020- 7-1) își păstrează caracterul de random walk.

Obiectivul 2:

Acest obiectiv face referire la distribuția de probabilitate a seriei de timp Tesla.

Vrem să aflăm:

1. Care este probabilitatea valorilor extreme?
2. Care este probabilitatea să am o pierdere mai mare de un anumit nivel?

Pentru realizarea acestor obiective vom folosi două metode.

A. Distribuția normală

Atunci când studiem un domeniu primul lucru pe care îl facem este să estimăm densitatea de probabilitate. În cazul piețelor de capital referința este fie distribuția normală, fie distribuția log-normală. Bachelier a vorbit primul despre mișcare browniană. Folosind proprietățile mișcării browniene putem să calculăm probabilitatea ca prețul unei acțiuni să se afle într-un anumit interval. De atunci s-a arătat **ineficiența** distribuției normale pentru piețele de capital.

În perioadele normale ale pieței este bine să utilizăm distribuția normală, ținând cont că: în mijlocul distribuției, 80% dintre valori provin dintr-o distribuție normală. Probleme apar în perioadele cu turbulențe, când extremele nu mai pot fi modelate de distribuția gaussiană.




Fig.10 Valori zilnice log-returns petru TSLA ('2010-06-29' - '2021-1-27')




Fig.10 Histograma pentru Log-returns vs Histograma pentru Simple Returns pentru TESLA ('2010-06-29' - '2021-1-27')

Când studiem distribuția randamentelor ne uităm în primul rând la Kurtosis (vedem dacă este mult mai mare decât 3).

Descriptive Statistics for log-return	
	logreturn
count	2409.000000
mean	0.001313
std	0.032291
min	-0.214772
50%	0.000851
max	0.218292
skewness	0.130623
kurtosis	5.782549

Fig.11 Indicatorii distribuției

Presupunem că randamentele TESLA urmează o distribuție normală cu media egală cu randamentul mediu (mean = 0.001313) și varianța de 0.032291.

```
Quantiles of the log-returns distribution
0.00   -0.214772
0.01   -0.082439
0.05   -0.047168
0.10   -0.032784
0.25   -0.014384
0.50    0.000851
0.75    0.017913
0.90    0.034120
0.95    0.047635
0.99    0.092985
1.00    0.218292
Name: logreturn, dtype: float64
```

Fig.12 Cuantilele distribuției Log-returns

```
Top 10 logreturn:
           logreturn
Date
2014-01-13    0.146163
2013-03-28    0.147910
2018-08-01    0.150039
2013-12-02    0.153011
2012-01-13    0.154589
2011-03-30    0.157339
2018-09-28    0.159966
2019-10-23    0.162707
2010-11-09    0.175668
2013-05-08    0.218292
```

Fig.13 Primele 10 Log-returns

```
Last 10 logreturn
           logreturn
Date
2012-01-12   -0.214772
2010-07-02   -0.175470
2010-12-23   -0.163556
2013-11-05   -0.156737
2013-07-15   -0.154426
2018-09-27   -0.149679
2019-07-24   -0.146341
2019-01-17   -0.138930
2010-07-01   -0.134312
2014-05-07   -0.119952
```

Fig.14 Ultimele 10 Log-returns

Fig. 15




Fig.16

Probabilitatea valorilor extreme

c	Pr(r<c)_empiric	Pr(r<c)_Normal
float64	float64	float64
-0.03	0.12005740649007228	0.1660945785209953
-0.06	0.02831809557267916	0.028797640640157857
-0.09	0.008807925377577462	0.002343324400137087

Concluzii:

Din tabelul de mai sus reiese faptul că, în realitate, probabilitatea să am o pierdere mai mare de 3% este de 1,2%. Probabilitatea să am o pierdere mai mare de 9% este 0,88%.

Dacă am modela după distribuția normală, probabilitatea să am o pierdere mai mare de 9% este 0,23%.

B. Distribuția Pareto (80, 20)

Noi nu o să folosim pentru randamente distribuție pareto, **ci o să presupunem că randamentele au cozi pareto**. De exemplu, coada stângă poate fi modelată cu o distribuție de tip pareto. Distribuția pareto o folosim drep distribuția pierderilor.

Distribuția randamentelor în niciun caz nu poate fi modelată cu distribuție pareto pentru că are și valori negative. Atunci, valorile negative se iau în modul și voi avea pierderi (adică valoarea absolută a randamentelor).

Funcția de repartiție a distribuției pareto:

$$F(x) = P(X < x) = 1 - \left(\frac{c}{x}\right)^\alpha, x > c > 0$$

Este o distribuție definită doar pentru valori pozitive. Este o funcție unimodală.

Funcția densitate de probabilitate este derivata funcției de repartiție.

$$f(x) = \frac{\alpha c^\alpha}{x^{\alpha+1}}, x > c$$

Parametru alfa este foarte important (tail index). Este indicele cozii. Valoarea lui este corelată cu probabilitate asociată cozii din dreapta a distribuției. Mai exact, cu cât alfa este mai mare cu atât probabilitatea asociată cozii din dreapta a distribuției este mai mică. Altfel spus, cu cât alfa este mai mare cu atât $\left(\frac{c}{x}\right)^\alpha$ tinde spre zero.

„c” - pragul inferior al pierderilor

Pași:

1. Accesam datele;
2. Calculăm randamentele și facem graficul lor
3. Estimăm funcția de repartiție empirică a randamentelor;
4. Reținem doar cele mai mici randamente (coada din stânga) : de regulă mai mici decât quartila de rang 10% sau 5% sau 1%.
5. Estimăm acest model de regresie
6. Minus panta modelului de regresie va fi coeficientul alfa
7. Estimăm probabilitatea unei valori extreme de parametrii a acestui model de regresie




Fig.17 Histograma și funcția densitate de probabilitate. Distribuția Pareto pentru randamentele TESLA

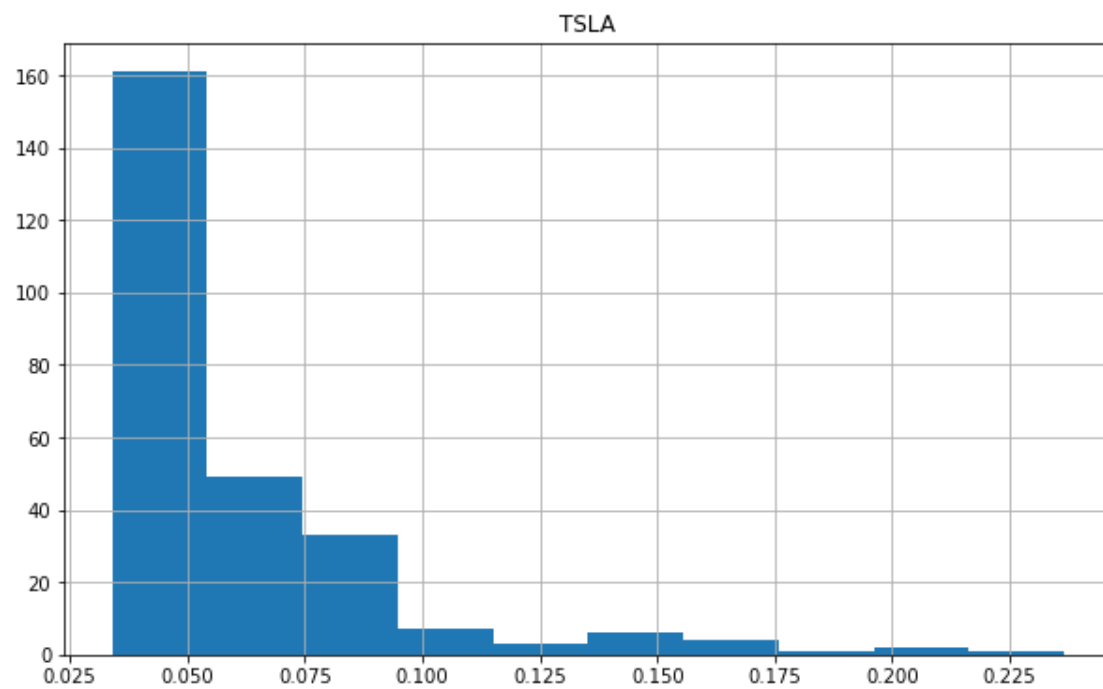


Fig.18 Coada stângă a distribuției randamentelor / Distribuția pierderilor (randamentele mai mici de 10%)




Fig.19 Modelul de regresie

Only the 10% lowest log-returns from the left tail are selected

Parameters of the Pareto Distribution

Estimated tail index $\alpha=3.257$

Estimated $x_{\min}=0.038$ (este pierderea minima, quantila de rang 10%)




Fig.20 Probabilitatea unei pierderi în cazul modelelor empiric, Pareto și a distribuției normale pentru acțiunile TESLA

Unde Axa OX: pierderea

Axa OY: probabilitatea pierderii

Concluzie:

Fig.20 este probabilitatea unei valori extreme folosindu-mă de acest model de regresie. De exemplu, Probabilitatea de a avea o pierdere mai mare 5% este 6,3%, lucru reflectat și de distribuția pareto. Dacă aș modela cu o distribuție normală, probabilitatea de a avea o pierdere mai mare decât 5% ar fi de 2,5%.

Concluzii generale:

1. Cu cât alfa este mai mare cu atât probabilitatea cozii este mai mică.
2. Dacă am două active sau două portofolii va fi mai riscant acel portofoliu care are alfa minim, deoarece cu cât alfa este mai mic, cu atât probabilitatea valorilor extreme este mai mare.
3. S-a dovedit de foarte multe ori că distribuția pareto chiar poate fi folosită pentru a estima probabilitatea valorilor extreme.

Bibliografie:

1. https://econ.ubbcluj.ro/Scoala_Doctorala/rezumat/PLESOIANU%20Mihaela%20Anita.pdf
2. http://www.eviews.com/help/helpintro.html#page/content/advtimeser-Variance_Ratio_Test.html
3. <https://finance.yahoo.com/quote/TSLA/history?p=TSLA>
4. <https://github.com/danpele>
5. <https://quantivity.wordpress.com/2011/02/21/why-log-returns/>
6. Joint Variance-Ratio Tests of the Martingale Hypothesis for Exchange Rates, Vol. 15, No. 1 (Jan., 1997), pp. 51-59 (9 pages) Published By: Taylor & Francis, Ltd., Journal of Business & Economic Statistics; <https://doi.org/10.2307/1392073>